Análisis de datos en salud: Introducción

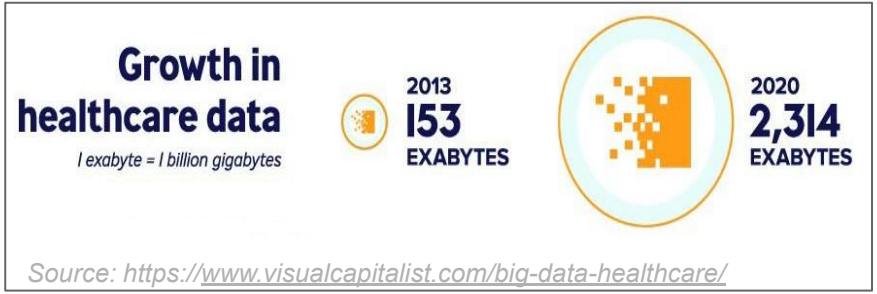
Author: Oswaldo Solarte Pabón

https:// medal.ctb.upm.es/

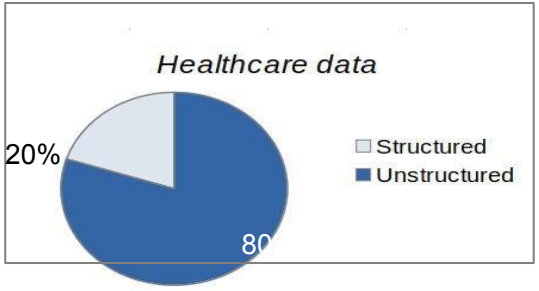
@MEDAL_CTB

Motivación

The health care process generates a huge amount of data. Hospitals produce **50 petabytes** of data **per year**[1].

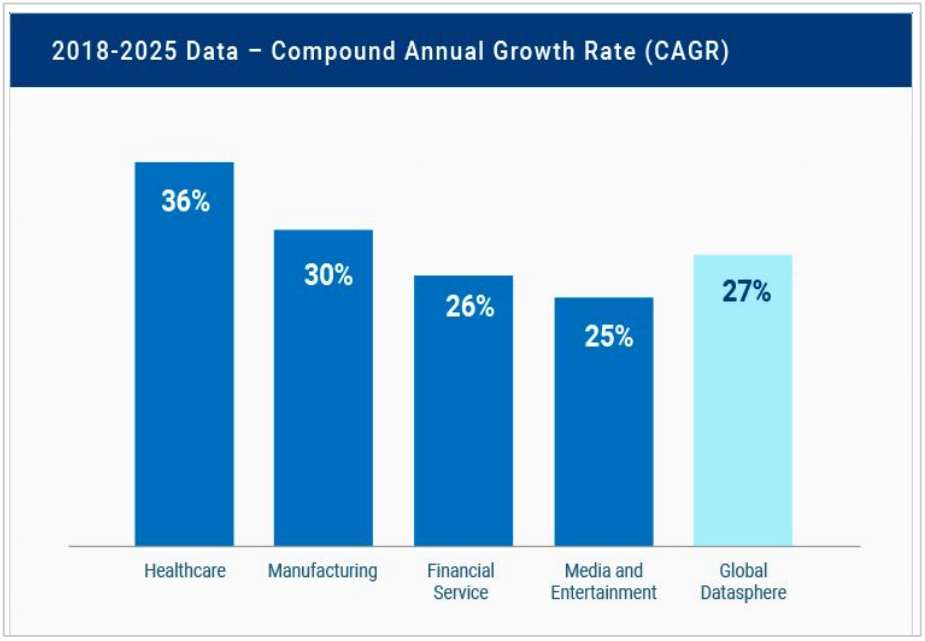


Source: https://www.visualcapitalist.com/big-data-healthcare/



Unstructured

- **Clininal texts**
- Images
- Others

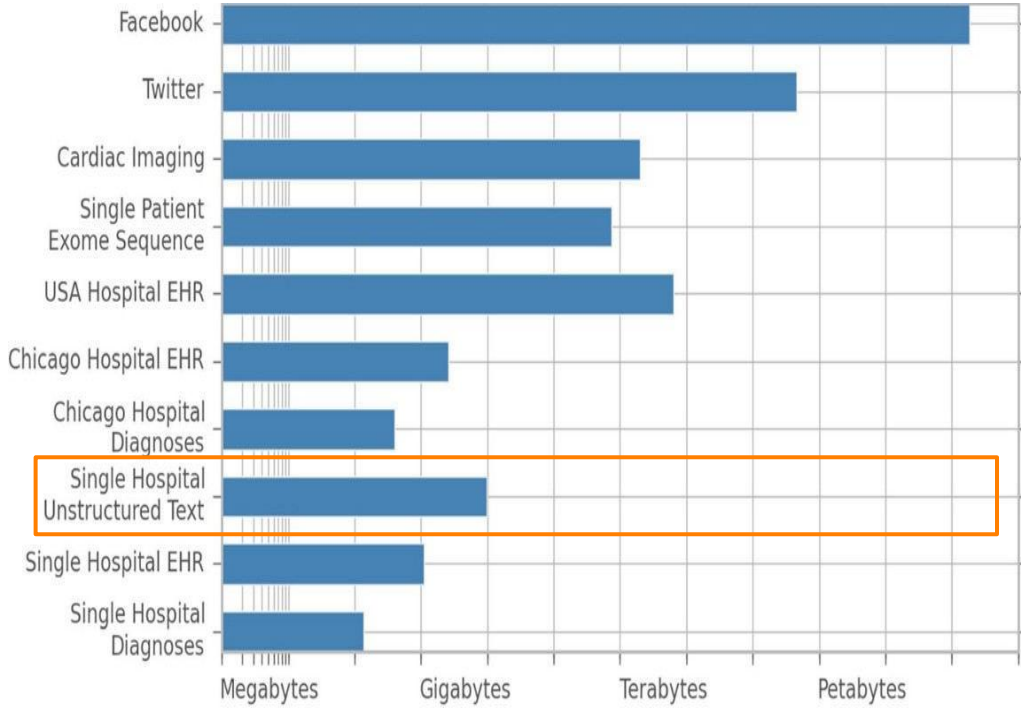


Source: (Capital markets)
https://www.rbccm.com/en/gib/healthcare/episode/the_healthcare_data_explosion

Source:
https://www.sciencedirect.com/topics/computer-science/healthcare-data

1. https://www.weforum.org/agenda/2019/12/four-ways-data-is-improving-healthcare

Motivación



Source: https://link.springer.com/article/10.1007/s12170-014-0424-3 (2015)

- 2015: the healthcare industry in the U.S. produced **1.2 billion** clinical text **documents**[2].
- 2021: Beth Israel Medical Center, Boston (**1 TB year**[3], clinical text)
- 2022: Cancer registry (Cali, Colombia) obtains 500,000 pathology reports/year. More than 10M reports accumulated.
- NLP in Healthcare market will be 6.8 billion USD by 2028.

2. https://www.databricks.com/blog/2021/07/01/applying-natural-language-processing-to-healthcare-text-at-scale.html
3. http://geekdoctor.blogspot.com/2011/04/cost-of-storing-patient-records.html

Análisis de datos en salud

Subconjunto de análisis de datos que utiliza **datos históricos** y actuales para producir información útil, mejorar la **toma de decisiones** y optimizar los resultados dentro de la industria de la atención médica.

Los análisis de atención médica no solo se utilizan para beneficiar a las organizaciones de atención médica, sino también para **mejorar la experiencia del paciente** y los resultados de salud.

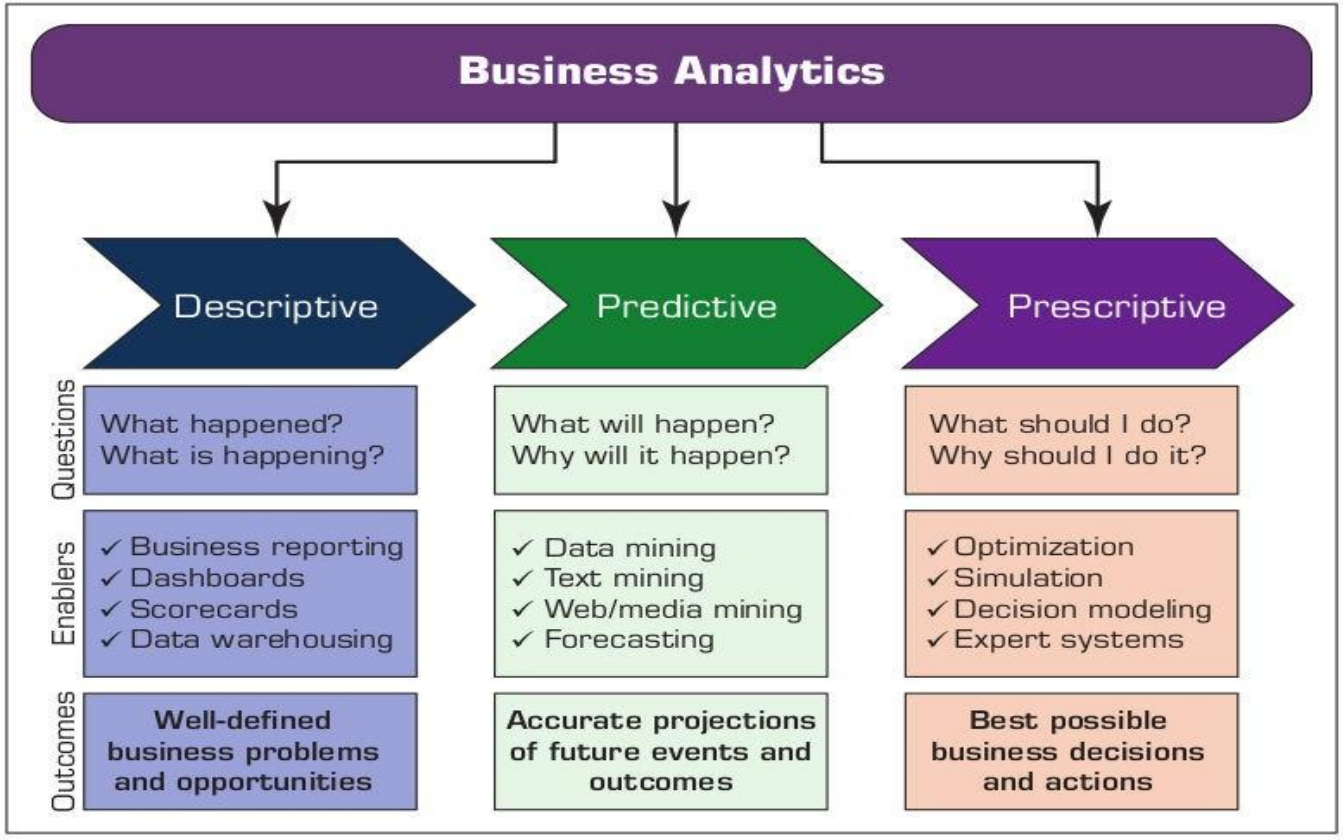


Análisis de datos en salud

"Information is the oil of the 21st century, and analytics is the combustion engine."

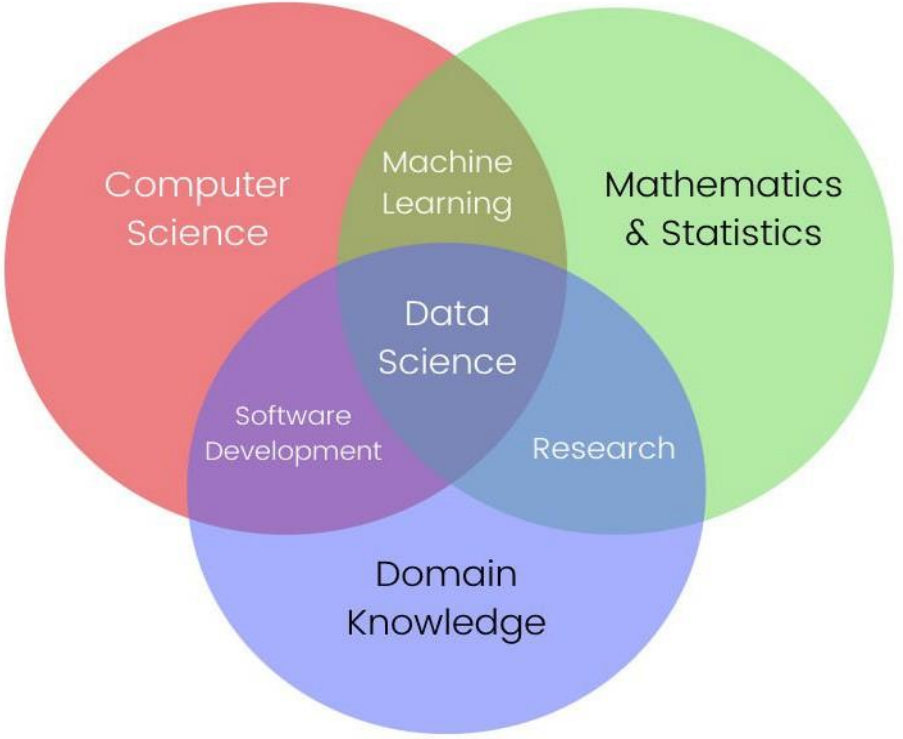


Análisis de datos en salud



Ciencia de datos

Combina utiliza conceptos de estadística, matemática y programación, en conjunto con herramientas tecnológicas, para **extraer información de los datos** para tomar mejores decisiones.



Análisis de datos en salud

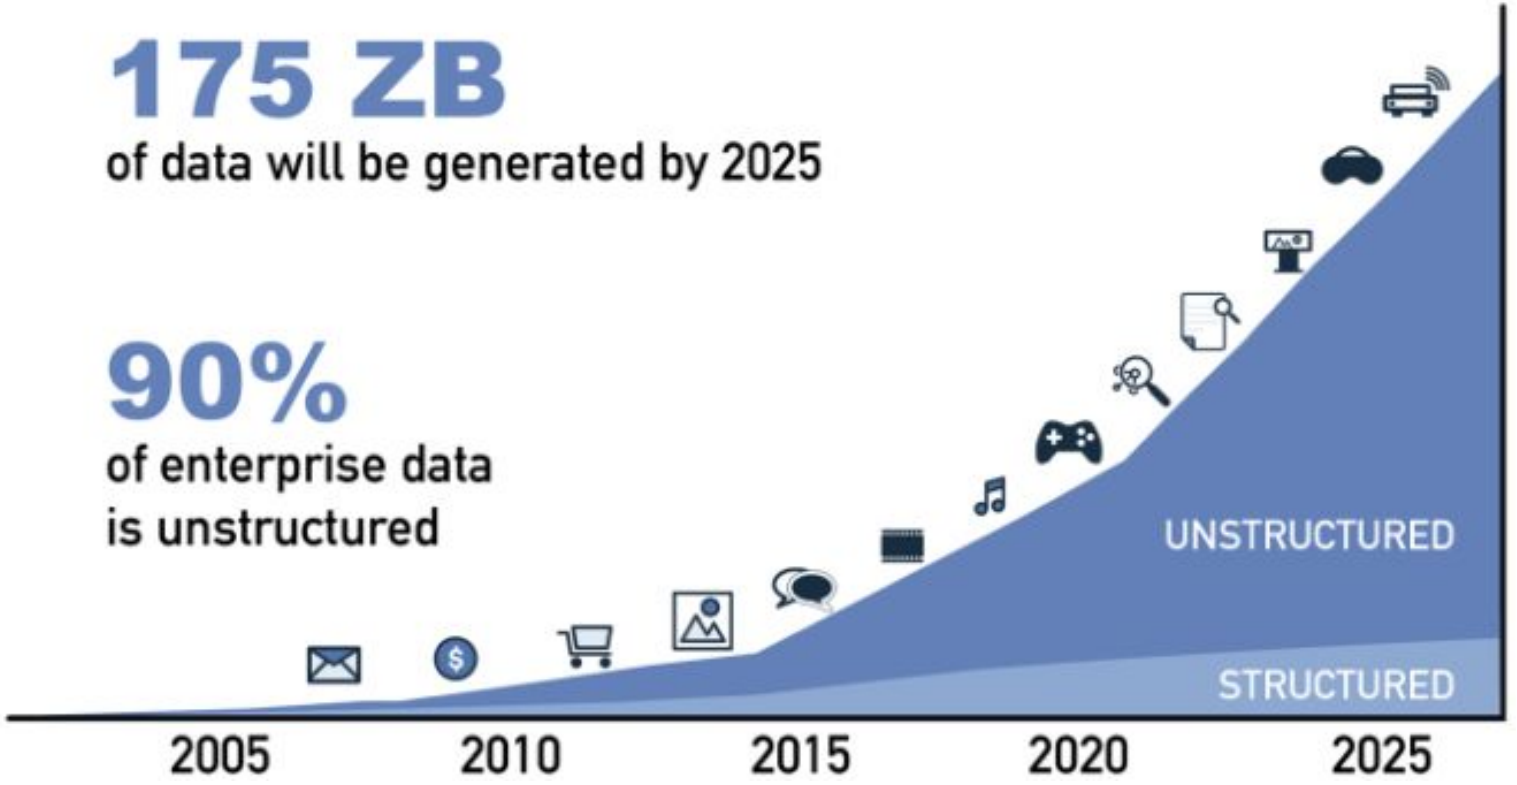


- Diferentes grados de **complejidad, ambigüedad** en los datos
- No pueden ser procesados utilizando **tecnologías tradicionales**

BIG DATA


BIG
DATA
STORAGE
VOLUME
PROCESSING
INFORMATION
VARIETY
VELOCITY
DECISION
SPEED
SHARING
COLLECTION
TOOLS
TRANSFER
ANALYSIS
CAPTURE
DATABASE
DIFFICULT
CHALLENGES
PROCESS
SEARCH
APPLICATIONS
EXPLORE
SIMULATION
DEPENDENCIES
STREAM
ENABLE
TRIGGER
ENHANCED
CAPABILITIES
BUSINESS
SOFTWARE
INTERNET
OPTIMIZATION
PETABYTES
AMOUNT
RELATIONAL
METEOROLOGY
STATISTICS
RANGE
SOURCES
SYSTEMS
SIZE
MANAGE
GOVERNMENT
DOUG
LANEY
CAMERAS
ENVIRONMENTAL
TOLERABLE
CONNECTOMICS
GROWS
DOMAIN
SENSOR
CURATE
TAKE
MAKING
NETWORKS
SIMULATIONS
RESEARCH
DENSITY
OUT
AREAS
DISCOVERY
WIRELESS
THINGS
TYPES
LOGS
INSIGHT
TRENDS
HIGH
VISUALIZATION
3V
COMPLEX
ASSETS
GARTNER
REQUIRE
FLOW
FORMS
ON-HAND
MANAGEMENT
PROCESSING
BLANKET
ANY
TERM
INCLUDE
DATA
TIME
ENTERPRISE
SCIENTISTS
PACKAGES
GENOMICS
TERABYTES
IN DATA
VELOCITY
REPORT
CAPTURE
PROCESS
BIG
INFORMATICS
STATISTICS
CAMERAS
AND
THAT
NEW
SOURCES
SYSTEMS
SIZE
MANAGE
GOVERNMENT
DOUG
LANEY

Naturaleza de los datos

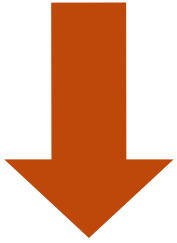


Análisis de datos en salud

GOAL

Provide **right** intervention to the **right** patient at the **right** time

ACQUIRE,
PROCESS, ANALYZE UNDERSTAND



PREDICT

Medicina basada en la Evidencia

Proceso cuyo objetivo es el de obtener y aplicar la mejor evidencia científica en el ejercicio de la práctica médica cotidiana.

Correlaciones, asociaciones de síntomas, antecedentes familiares, hábitos, enfermedades.

Impacto de determinados factores biomédicos (estructura del genoma, variables clínicas) en la evolución de determinadas enfermedades.

Que datos hay?

Hospital medio de 300 camas

Pacientes: 500.000 (población de referencia)
Usuarios: 1300 (250 médicos, 900 enfermeras y técnicos, 150 tareas administrativas)

Actividad mensual:

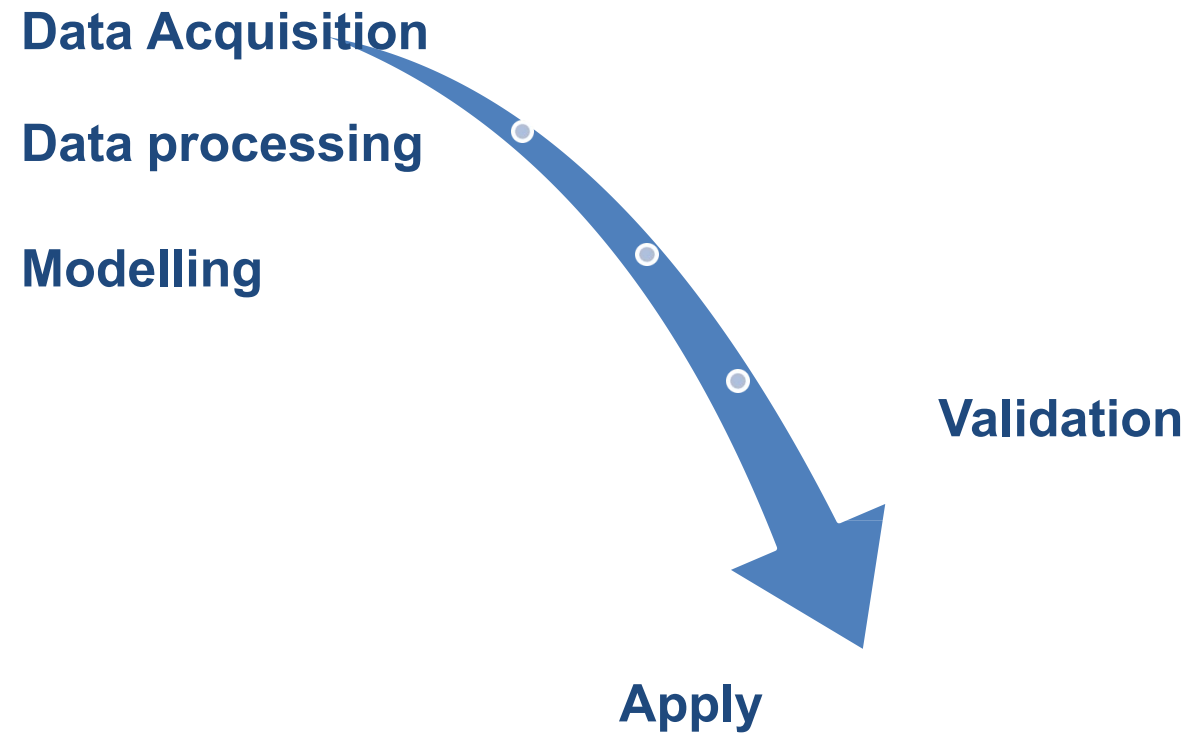
- 20.000 consultas, 1300 admisiones, 800 intervenciones,
- 10.000 urgencias
- 75.000 notas clínicas

Que datos hay?

500 petabytes de datos digitales para alcanzar 25,000 petabytes

¿Podemos aprender del pasado para ser mejores en el presente?

From data to knowledge



Retos

1. Diversidad de los Datos

Estructurados
Imágenes Genoma Texto clínico



Retos

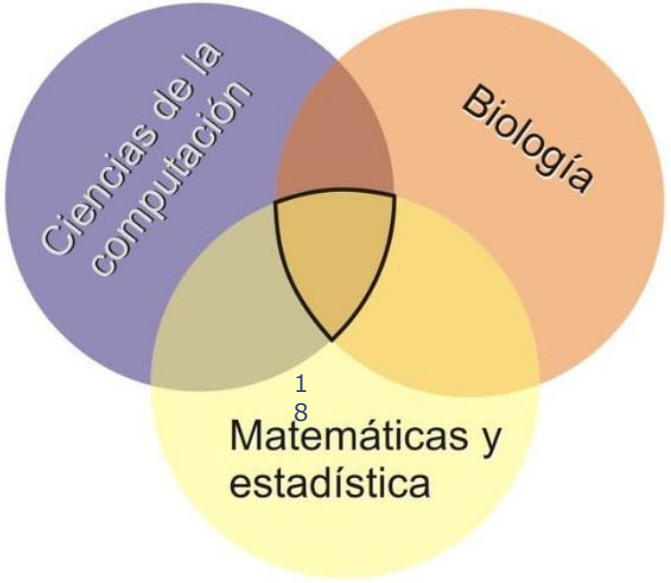
1. Diversidad de los Datos (Texto clínico)

Paciente varón de 68 años de edad, fumador de 20 cigarrillos/día hasta los los 60 años. Niega reacciones alergicas. Sin signos de TPV. Ingresa a nuestro centro para valoración por sospecha de ca de pulmón en mayo de 2017, remitido por su medico familiar. No diabetes mellitus, no hipertesion arterial. AF: Padre diagnosticado con cancer de próstata en 2001. Resumen de la historia oncológica: 06/2017: Adenocarcinoma de pulmón cT4N20 tratado con Carboplatino y Paclitaxel por 3 ciclos con RP por lo que se realiza tratamiento secuencial RT/QT (RT toráxica 30 Gy). No fiebre, no soplos, no nauseas. Reacción infusional moderada en sexta semana con carboplatino, sin evidenciar alergia. 03/10/2018: Progresion pulmonar lenta por PET en la zona radiada confirmada, EGFR y ALK negativos. 07/2018: Progresión ganglionar mediastínica y osea múltiple. No muestra reducción del dolor toráxico. Tratado con Carboplatino y Pemetrexed 50 mg cada 21 dias. PDL1 negativo, ROS1 negativo. Adenocarcinoma pulmonar cT4N2M0 estadio IV. Se suspende por probable toxicidad farmacologica. Posible afectación renal. Aceptable tolerancia al tratamiento. Probable metástasis cerebral. Próxima revisión en una semana.

Retos

1. Diversidad de los Datos (Bioinformática)

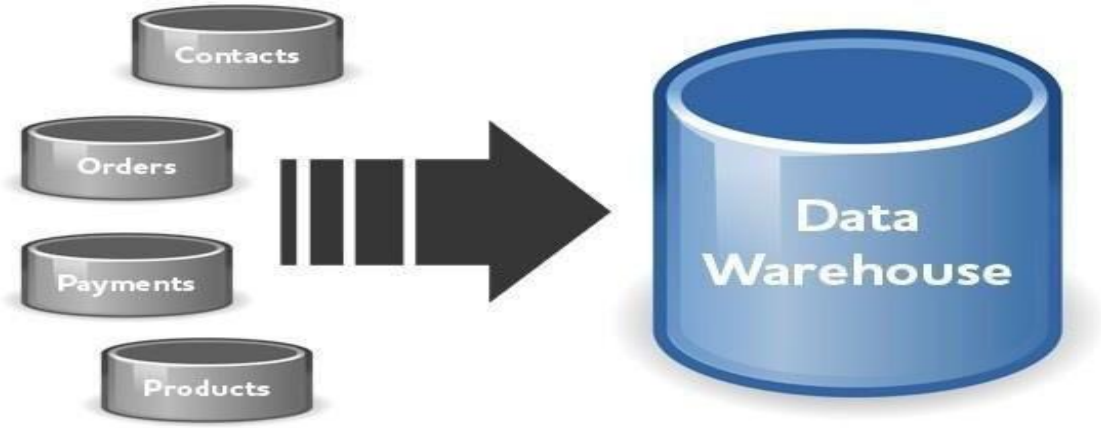
La bioinformática permite investigar, des
herramientas informáticas y computacio
permitir y mejorar el manejo de datos bio



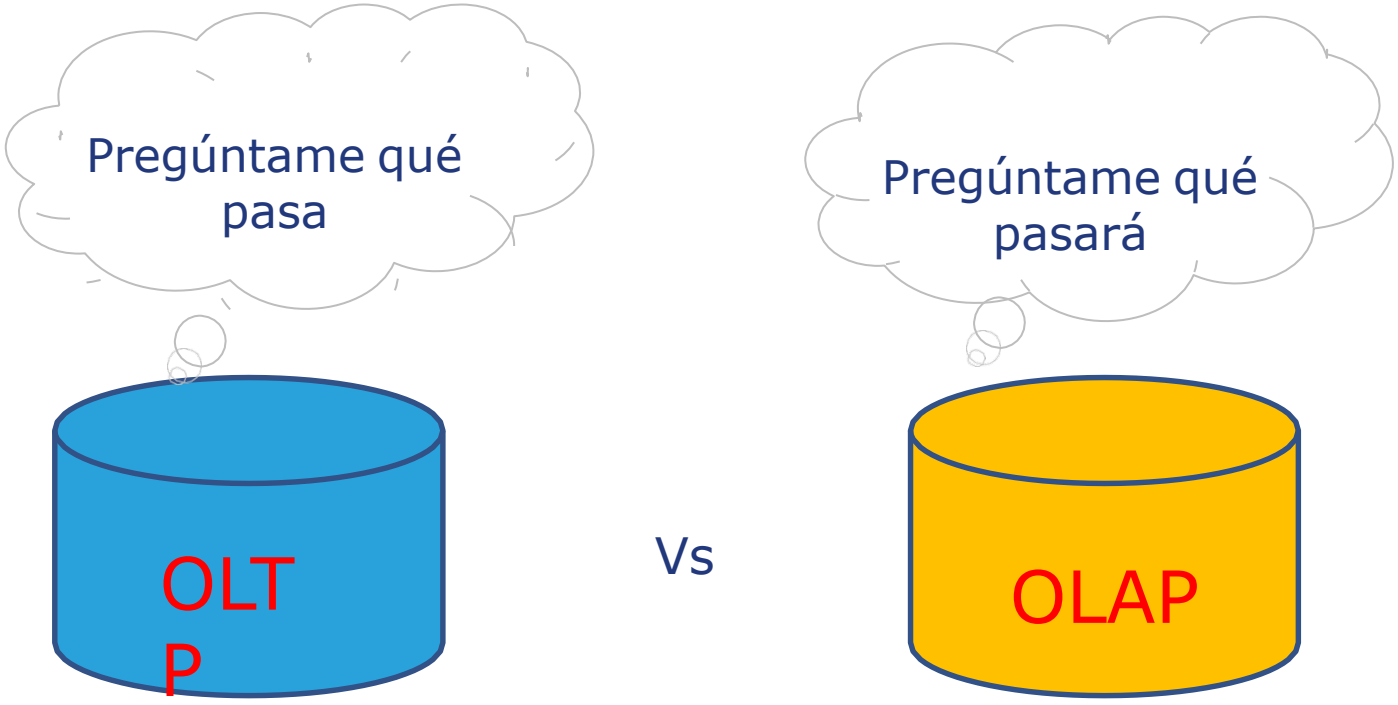
Retos

Integración de los datos

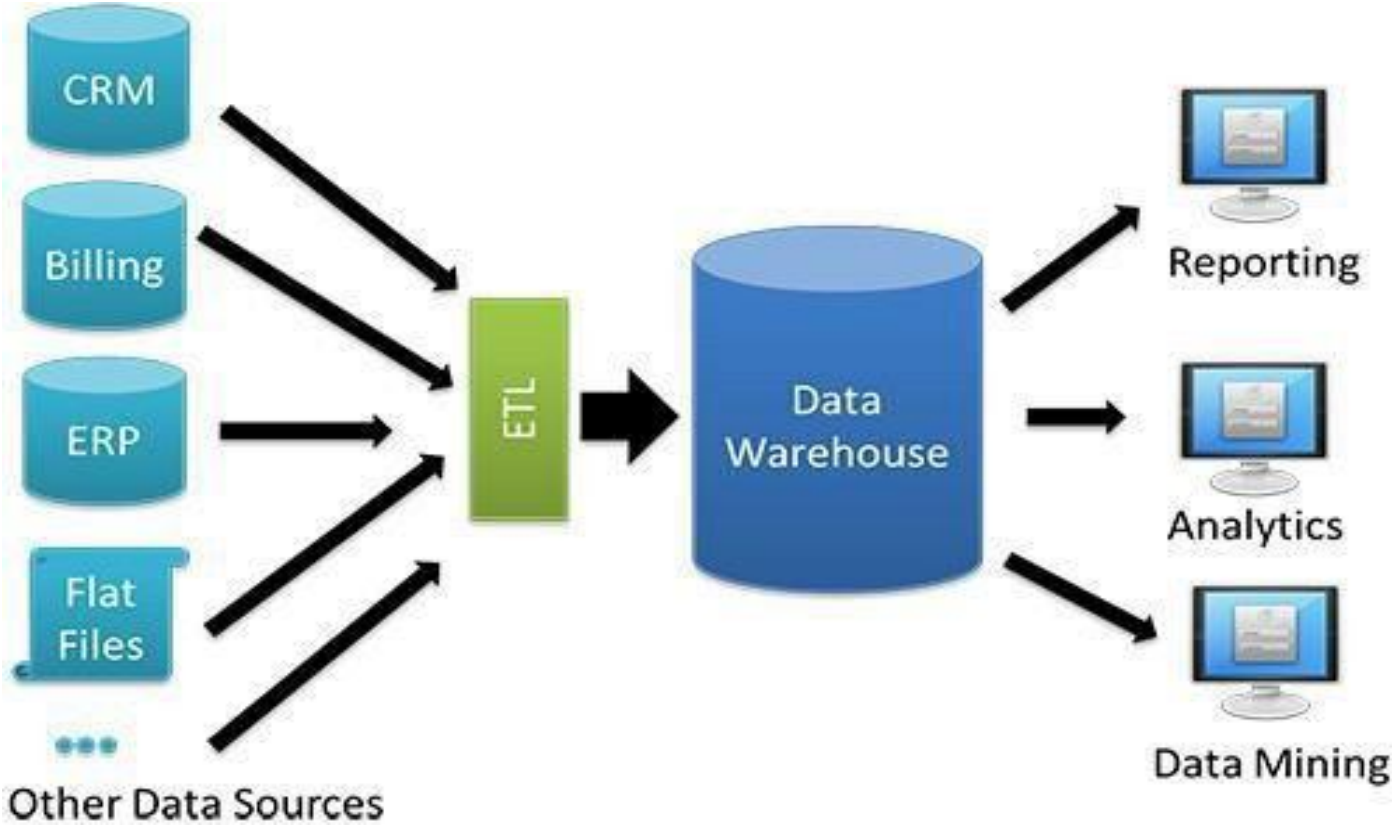
Integración y tratamiento de los **datos** para **convertirlos** en **información**
que permita apoyar a los tomadores de decisiones en la organización



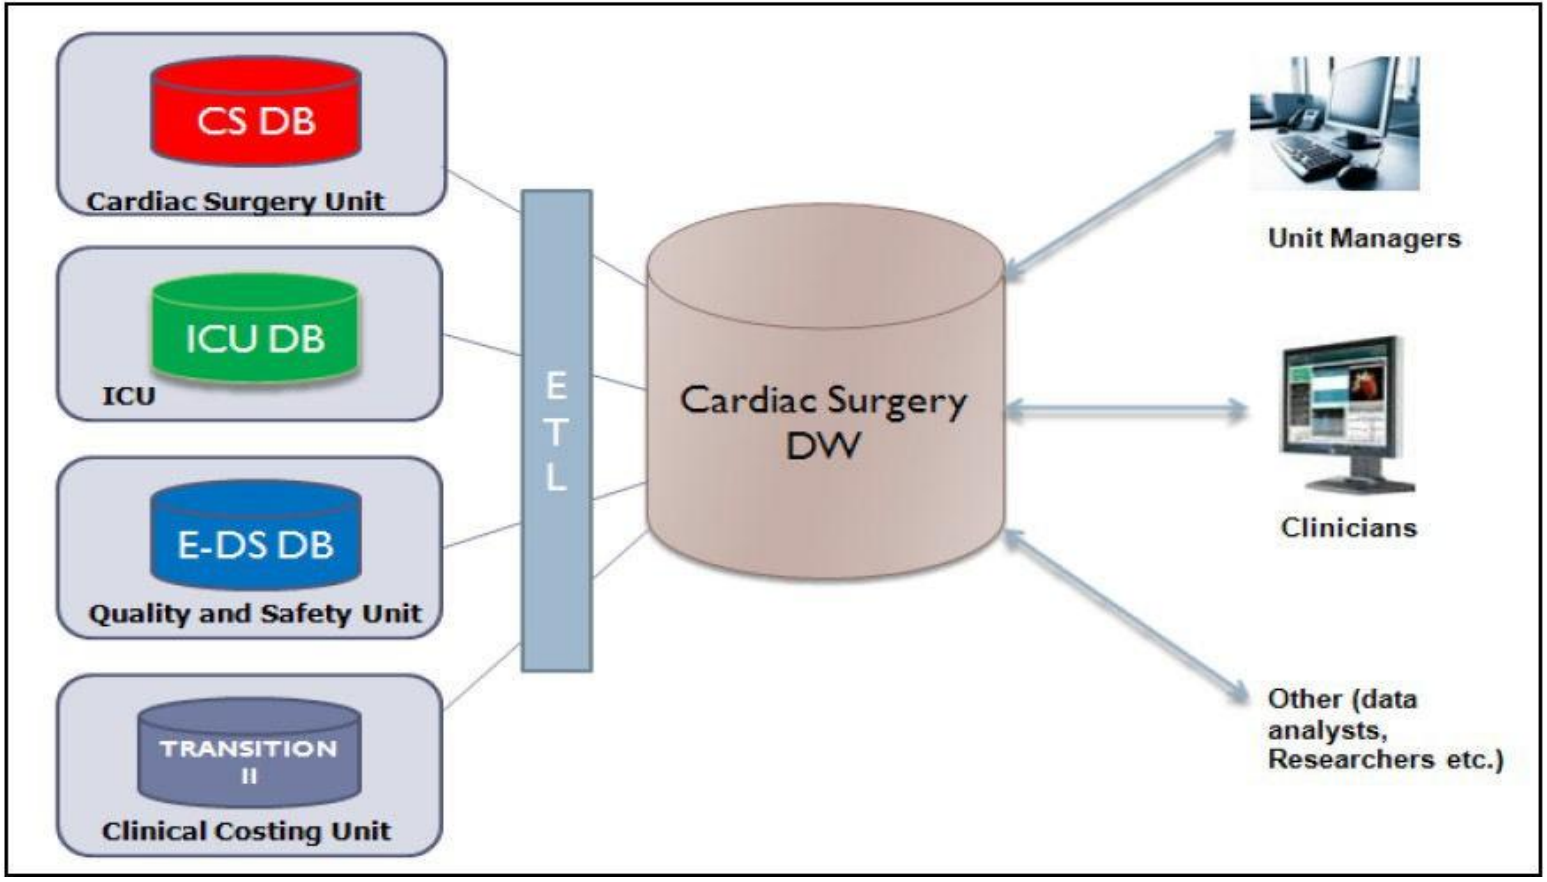
Business Intelligence (BI)



Bodega de datos



Bodega de datos clínica



Retos

Texto clínico: Retos

Paciente varón de 68 años de edad, fumador de 20 cigarrillos/día hasta los los 60 años. Niega reacciones alergicas. Sin signos de TPV. Ingresa a nuestro centro para valoración por sospecha de ca de pulmón en mayo de 2017, remitido por su medico familiar. No diabetes mellitus, no hipertesion arterial. AF: Padre diagnosticado con cancer de próstata en 2001.

Registro poblacional de Cáncer de Cali:
250.000 reportes de patología al año

Texto clínico: Retos



Named entity Recognition, Negation detection, Relation Extraction

Retos en el texto clínico

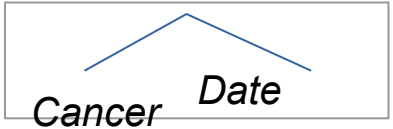
Paciente varón de 68 años de edad, fumador de 20 cigarrillos/día hasta los los 60 años. Niega reacciones alergicas. Sin signos de TPV. Ingresa a nuestro centro para valoración por sospecha de ca de pulmón en mayo de 2017, remitido por su medico familiar. No diabetes mellitus, no hipertesion arterial. AF: Padre diagnosticado con cancer de próstata en 2001. Resumen de la historia oncológica: 06/2017: Adenocarcinoma de pulmón cT4N20 tratado con Carboplatino y Paclitaxel por 3 ciclos con RP por lo que se realiza tratamiento secuencial RT/QT (RT toráxica 30 Gy). No fiebre, no soplos, no nauseas. Reacción infusional moderada en sexta semana con carboplatino, sin evidenciar alergia. 03/10/2018: Progresion pulmonar lenta por PET en la zona radiada confirmada, EGFR y ALK negativos. 07/2018: Progresión ganglionar mediastínica y osea múltiple. No muestra reducción del dolor toráxico. Tratado con Carboplatino y Pemetrexed 50 mg cada 21 dias. PDL1 negativo, ROS1 negativo. Adenocarcinoma pulmonar cT4N2M0 estadio IV. Se suspende por probable toxicidad farmacologica. Posible afectación renal. Aceptable tolerancia al tratamiento. Probable metástasis cerebral. Próxima revisión en una semana.

Finding entities

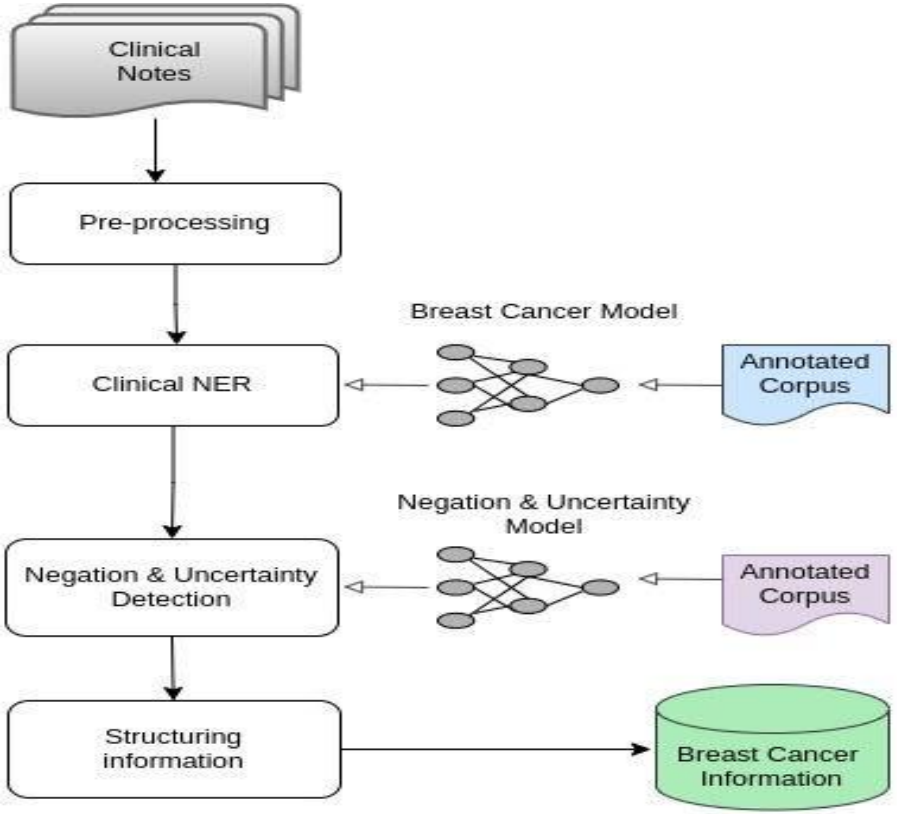
- *Cancer diagnosis*
- *Dose*
- *Dates*
- *Medication*

- *Negation*
- *Uncertainty*

Relationships



Estructurar la información: Retos

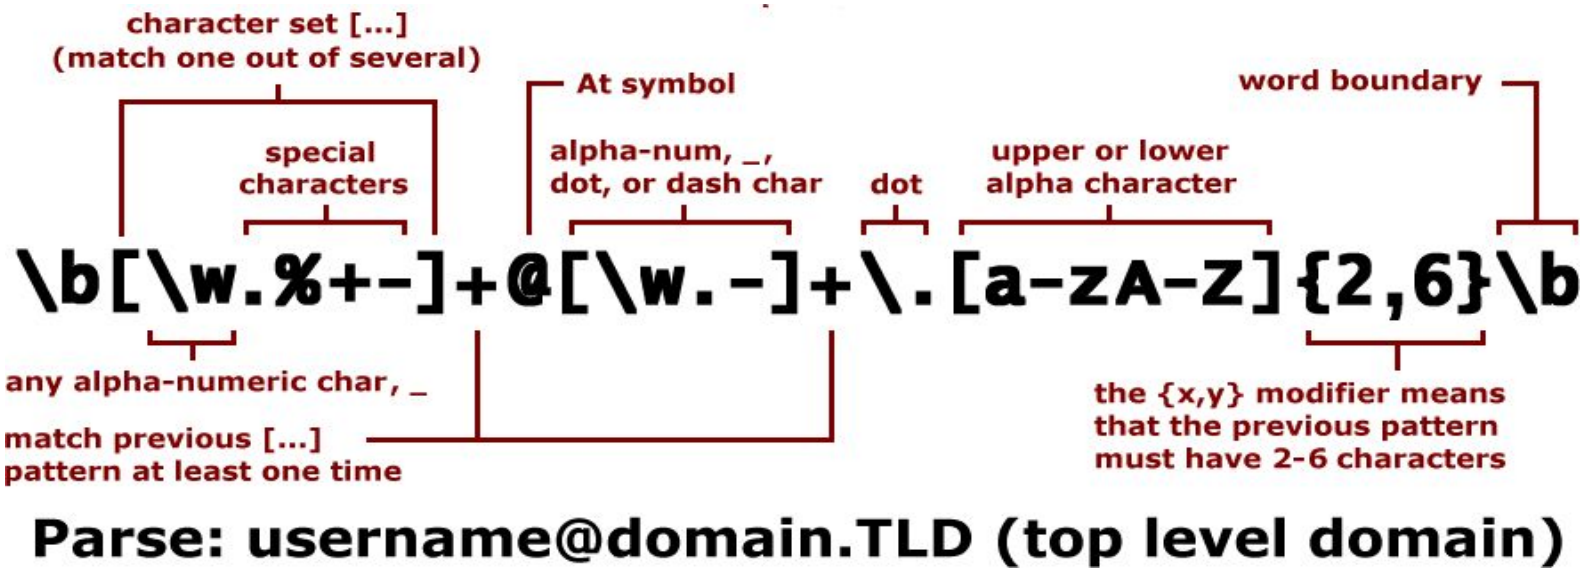


Estructurar la información es el primer paso que se debe hacer si se quiere hacer análisis de datos médicos.

Enfoques basados en IA

Cómo extraer información de las notas clínicas???

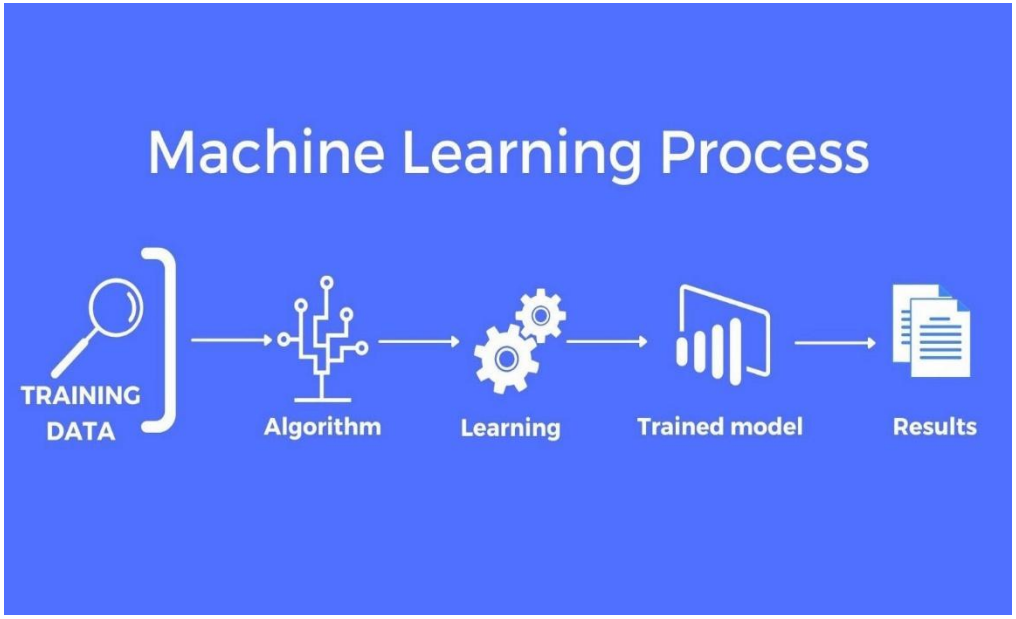
Enfoque basado en Reglas

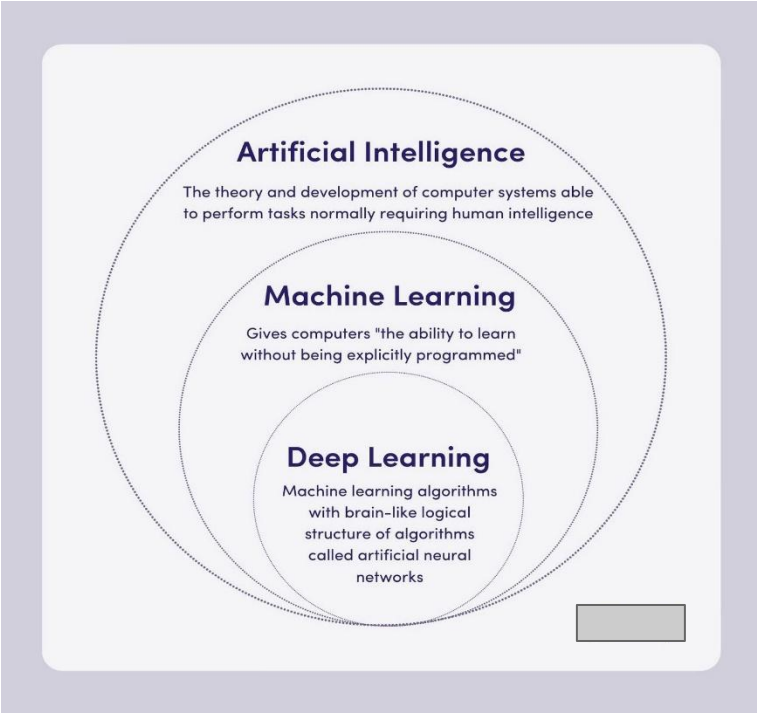


Enfoques basados en IA

Cómo extraer información de las notas clínicas???

Enfoque basado en machine-learning

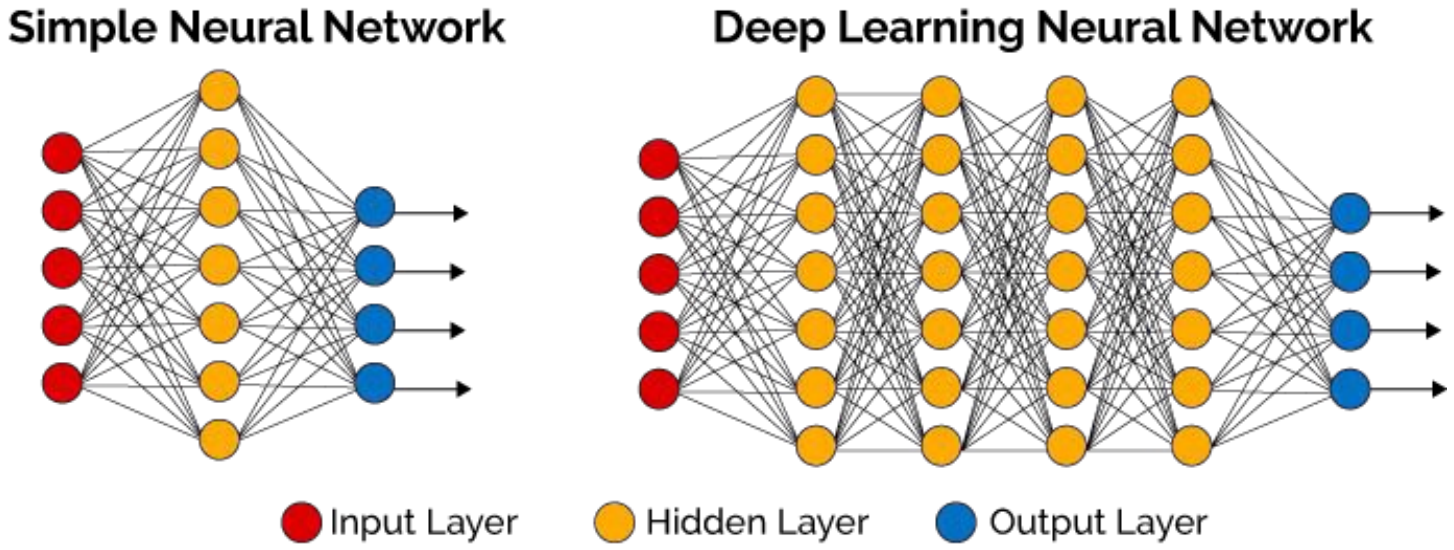




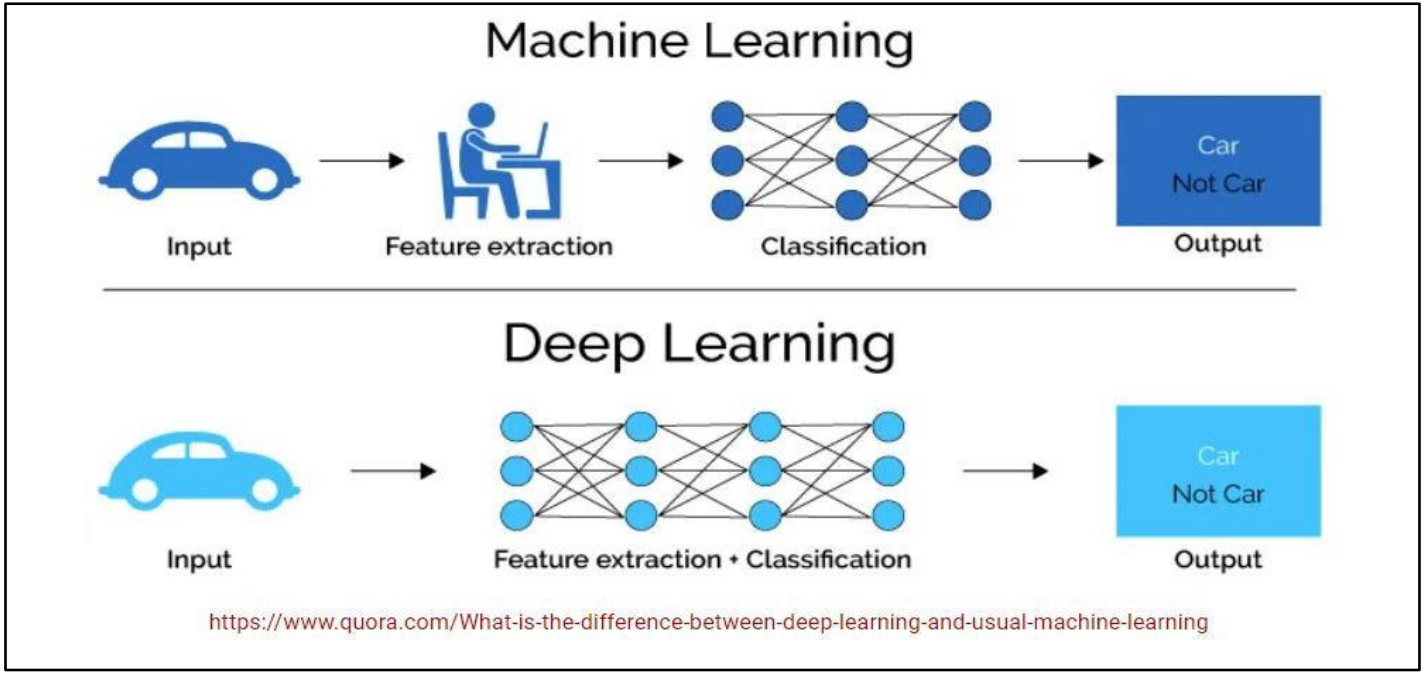
Enfoques basados en IA

Cómo extraer información de las notas clínicas???

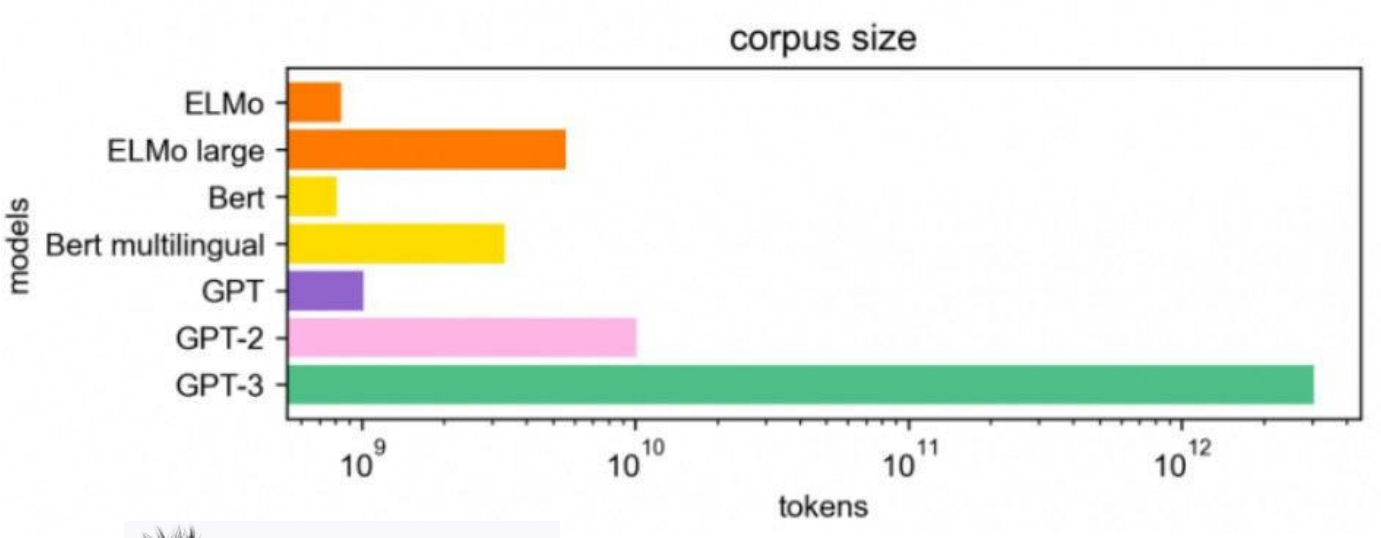
Enfoque basado en deep-learning



ML Vs - Deep Learning



Language Models







Language Models



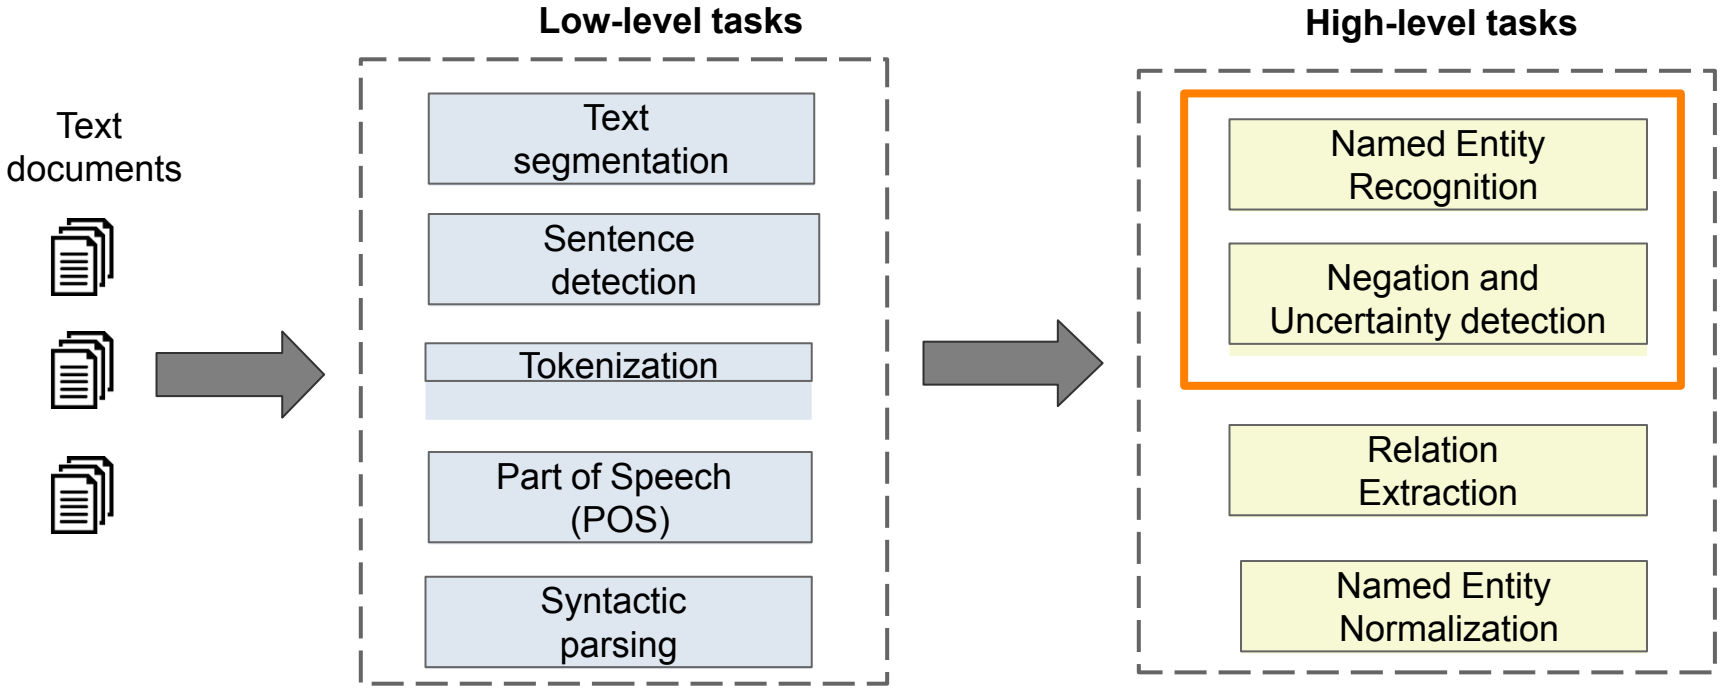




Mistral AI

Extracción de información

Proceso para **extrarer automáticamente información** del texto. En el dominio médico, de notas clínicas. Tarea influenciada por el **NLP**



En resumen ...

1) Integración de información: Bodegas de datos clínicas

2) Extracción de Información del texto clínico:

- Reglas
- Machine learning
- Deep learning

3) Machine learning para crear modelos predictivos en el dominio médico

Qué es la Inteligencia Artificial?

Qué es la IA?

- La I**nteligencia Artificial** (IA) es un campo de la computación que se enfoca en **desarrollar sistemas** capaces de realizar tareas que requieren inteligencia humana. Estas tareas incluye el **reconocimiento de patrones**, el **aprendizaje**, la **toma de decisiones** y la **resolución de problemas**.

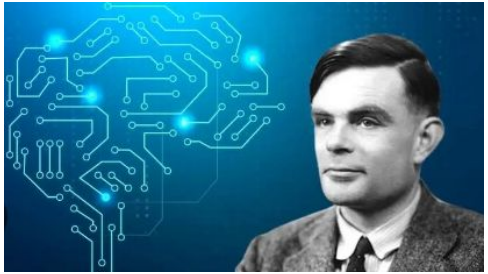
- La IA se basa en algoritmos que pueden **procesar datos, aprender** de ellos y **aplicar** ese aprendizaje para realizar predicciones o tomar decisiones.



Qué es la IA?

Exploring the Historical Journey of Artificial Intelligence

1942	1950	1955	1964	1995	1997	1998	2008	2011	2020
1	2	3	4	5	6	7	8	9	10
Enigma broken with AI	Test for machine intelligence by Alan Turing	The father of AI – John McArthy	The first chatbot – Eliza	The chatbot ALICE	Man vs Machine – DeepBlue beats chess legend	The emotionally equipped robot – Kismet	Voice recognition feature	The Q/A computer system – IBM Watson	A revolutionary tool for automated conversations – GPT models



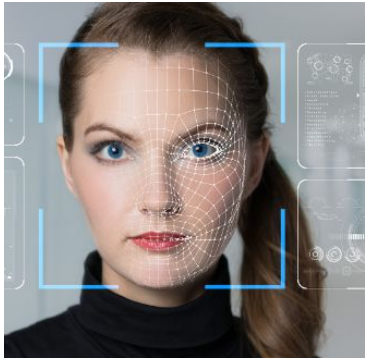
Alan Turing

Londres, 23 de junio de 1912- 7 de junio de 1954)

Qué es la IA?

- Asistentes de voz
- Reconocimiento facial
- Navegación Web
- Recomendaciones personalizadas
- Fotografía y edición de imágenes
- Detección de Fraude

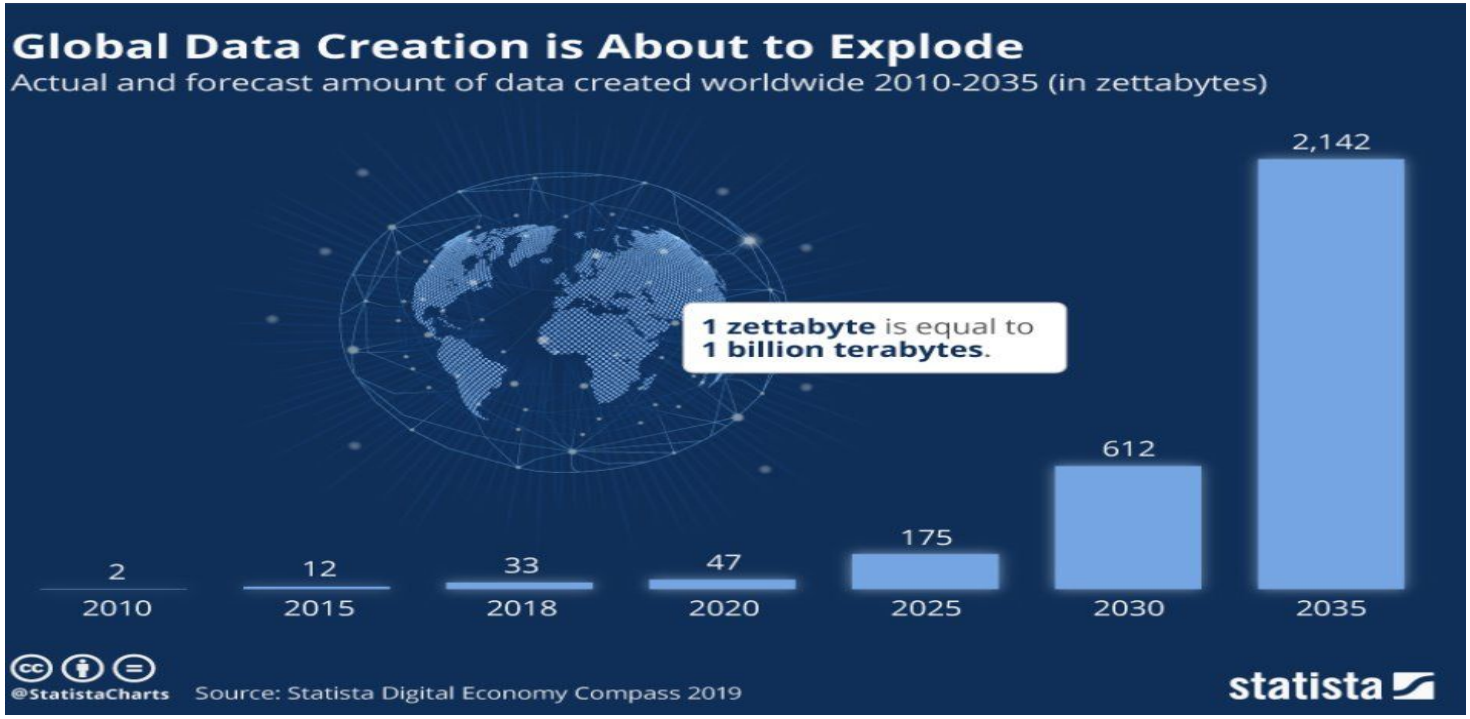




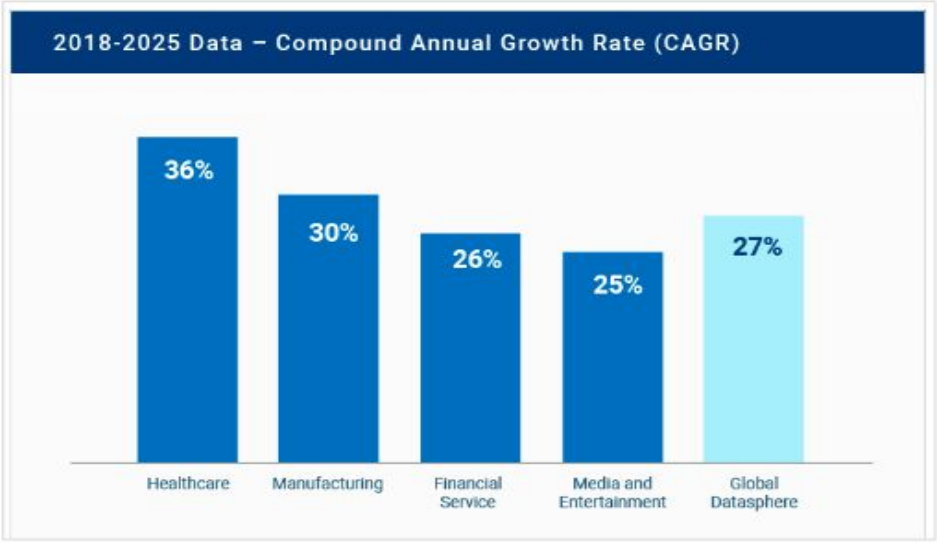


NETFLIX

Por qué ahora?



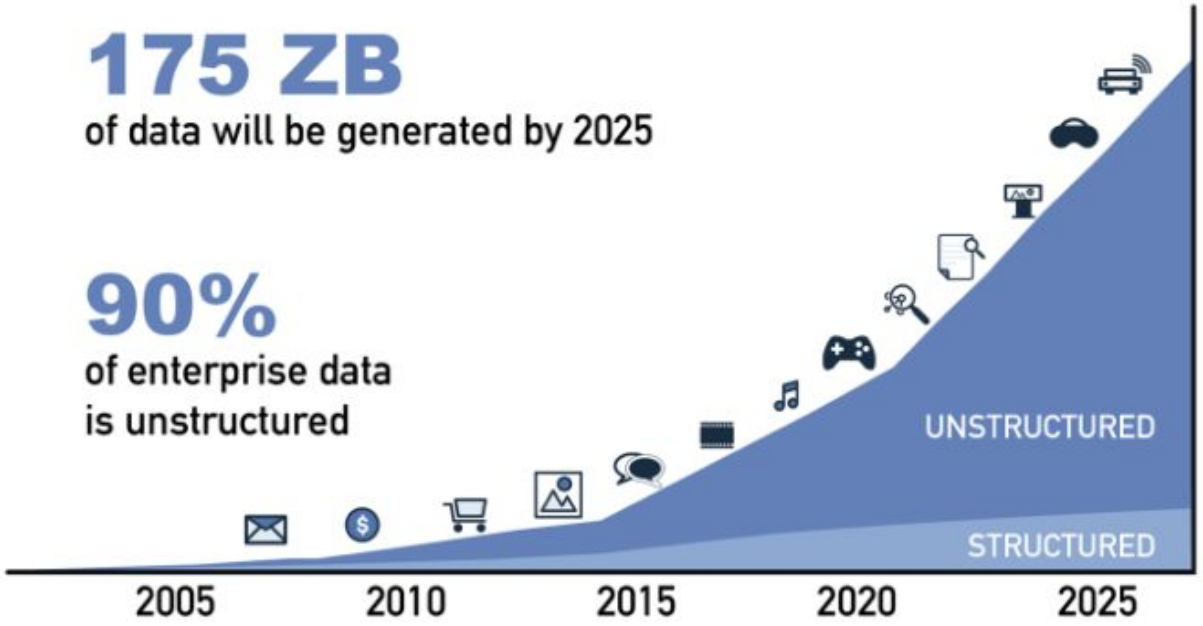
Generación de datos en Salud



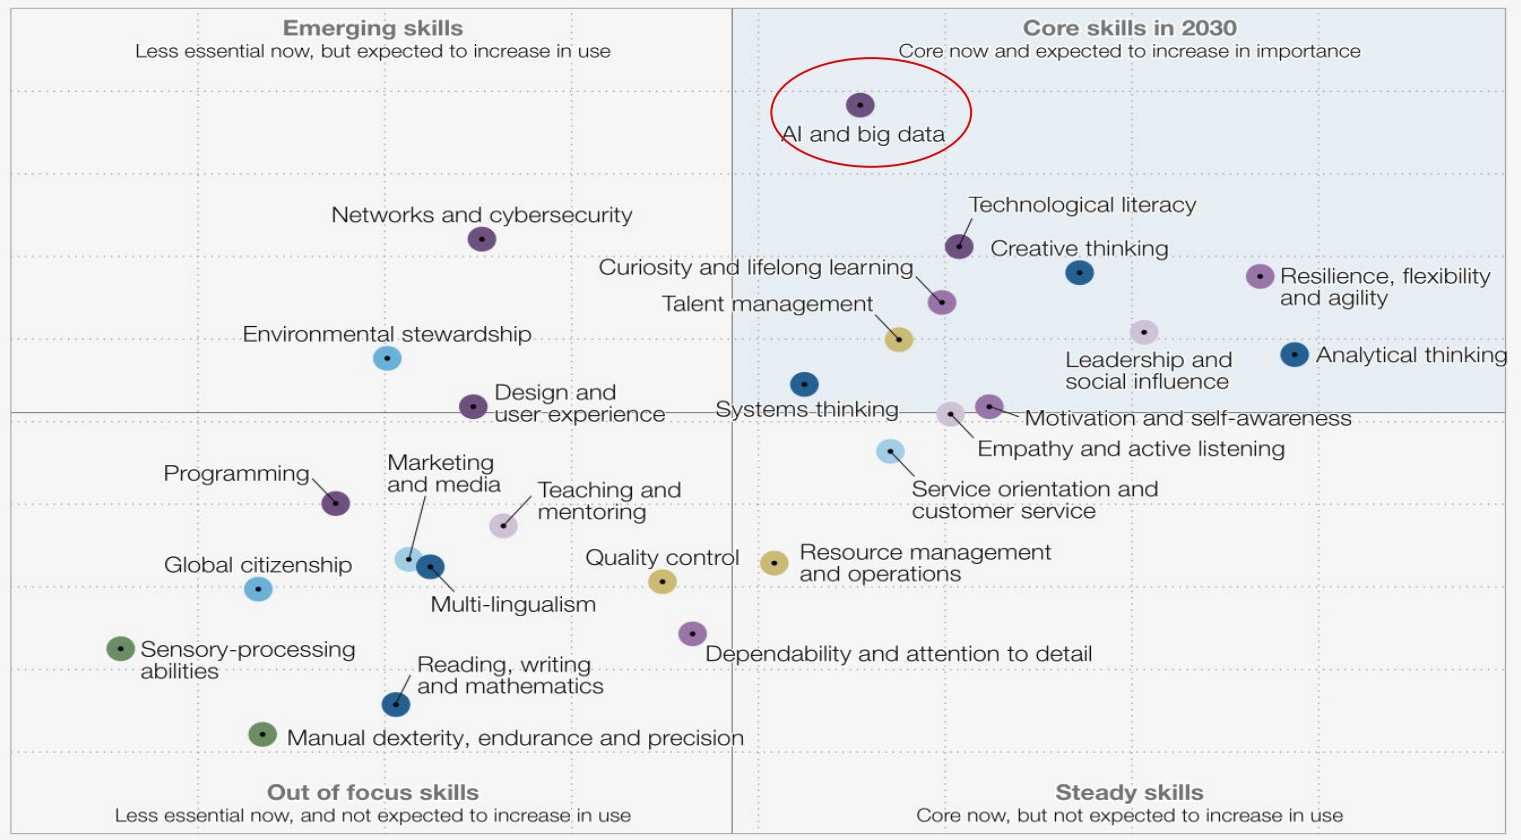
- **Clinical texts (EHR)**
- Administrative Data
- Diagnosis & Procedure Codes
- Health Surveys
- Clinical Trial Data
- Genomic Data
- Medical Images

Source: (Capital markets) https://www.rbccm.com/en/gib/healthcare/episode/the_healthcare_data_explosion

Datos Estructurados Vs No Estructurados



Core Skills - 2030



https://www.weforum.org/publications/the-future-of-jobs-report-2025/in-full/3-skills-outlook/

Impacto de la IA en la sociedad

- Educación
- Salud
- Investigación
- Industria
- Justicia, Gobierno









IA en el sector Salud

HARVARD MEDICAL SCHOOL | BLAVATNIK INSTITUTE BIOMEDICAL INFORMATICS

MEDICAL EDUCATION | ISSUE 2 / 2025

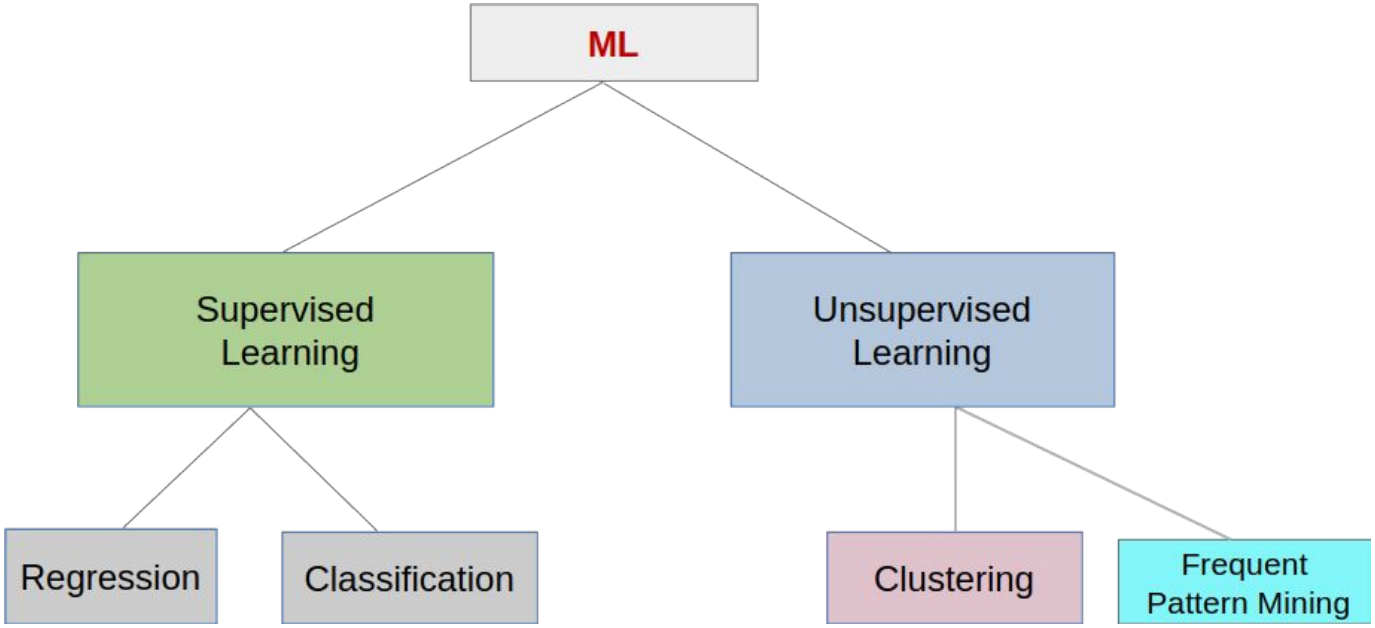
Paging Dr. Algorithm

At Stanford Medicine, AI is becoming part of the curriculum, clinical training and the future of care

MAYO CLINIC

Mayo Clinic's Department of Artificial Intelligence and Informatics includes clinical and research faculty and operational staff who drive **discovery and innovation through artificial intelligence** (AI) and informatics research to **enhance healthcare**.

Machine Learning



Campo de la IA que usa algoritmos que tienen la capacidad de **aprender** patrones en datos masivos y elaborar predicciones.

Datasets en el sector Salud

Datasets en el sector Salud

HARVARD MEDICAL SCHOOL | BLAVATNIK INSTITUTE BIOMEDICAL INFORMATICS

n2c2 NLP Research Data Sets

Unstructured notes from the Research Patient Data Registry at Partners Healthcare (originally developed during the i2b2 project)

https://portal.dbmi.hms.harvard.edu/projects/n2c2-nlp/

UC Irvine Machine Learning Repository

Heart Disease
4 databases: Cleveland, Hungary, Switzerland, and the VA Long Beach
Classification | Multivariate

Breast Cancer Wisconsin (Diagnostic)
Diagnostic Wisconsin Breast Cancer Database.
Classification | Multivariate

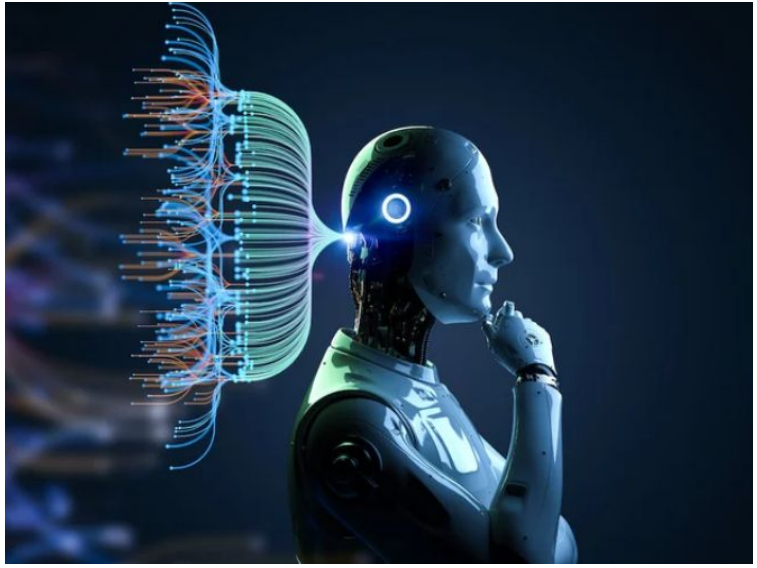
Diabetes
This diabetes dataset is from AIM '94
Classification | Multivariate, Time-Series

IA Generativa

La **IA generativa** es un tipo de inteligencia artificial que puede crear contenido nuevo y original, como **texto**, **imágenes**, **música**, **audio** y **video**, a partir del análisis previo de **grandes cantidades de datos**

ChatGPT

Claude Ai



IA Generativa

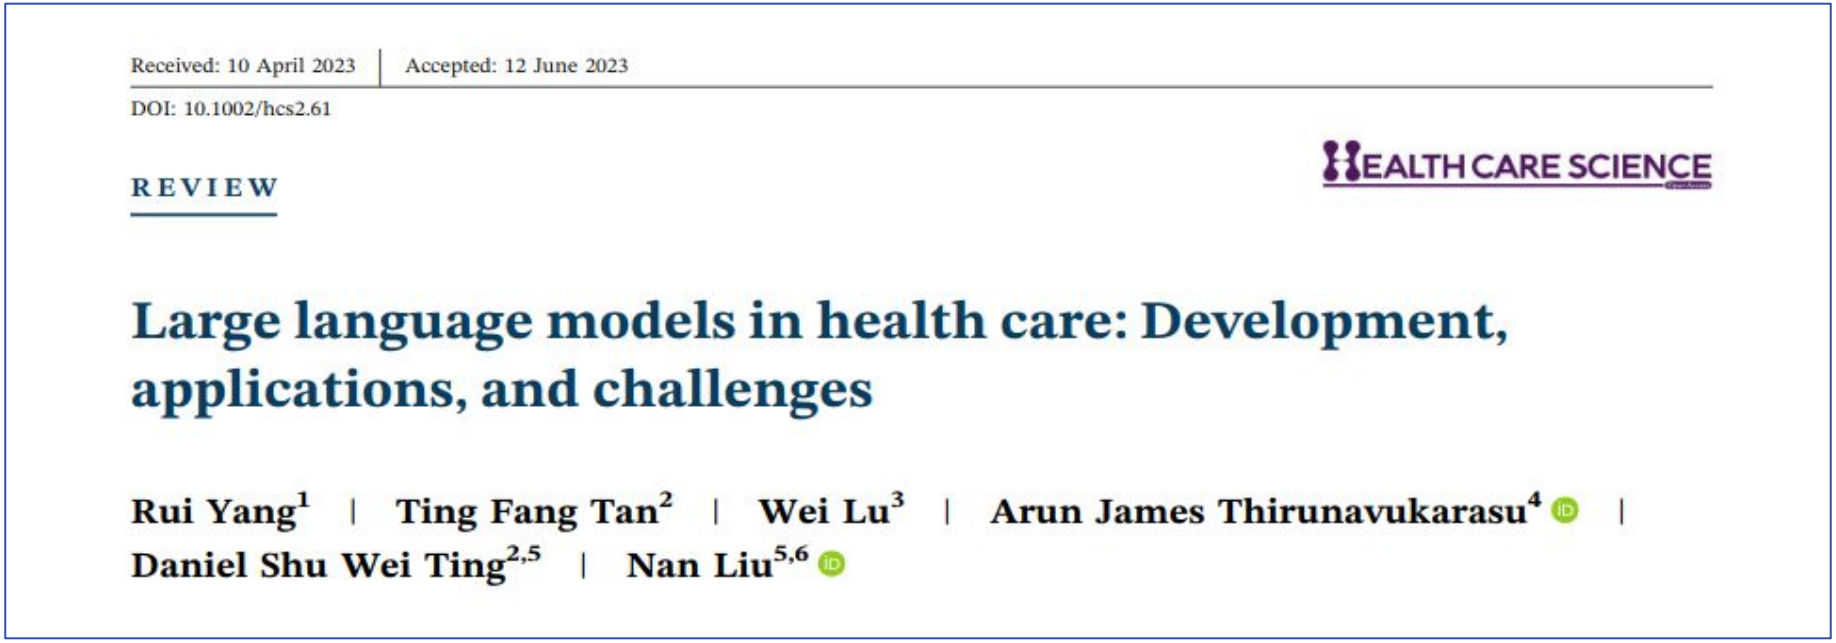
La **IA generativa** es un tipo de inteligencia artificial que puede crear contenido nuevo y original, como **texto**, **imágenes**, **música**, **audio** y **video**, a partir del análisis previo de **grandes cantidades de datos**

Ventajas y desventajas?





IA Generativa



Received: 10 April 2023 | Accepted: 12 June 2023

DOI: 10.1002/hcs2.61

REVIEW

HEALTH CARE SCIENCE

Large language models in health care: Development, applications, and challenges

Rui Yang[1] | Ting Fang Tan[2] | Wei Lu[3] | Arun James Thirunavukarasu[4] | Daniel Shu Wei Ting[2,5] | Nan Liu[5,6]

https://onlinelibrary.wiley.com/doi/epdf/10.1002/hcs2.61

Marco Normativo



En noviembre de 2021, la UNESCO elaboró la primera norma mundial sobre la ética de la IA: la **"Recomendación sobre la ética de la inteligencia artificial".**

La protección de los **derechos humanos** y la dignidad es la piedra angular de la Recomendación, basada en el avance de principios fundamentales como la **transparencia** y la **equidad**, recordando siempre la importancia de la supervisión humana de los sistemas de IA.

Marco Normativo

Ley de IA de la UE: primera normativa sobre inteligencia artificial

La prioridad del Parlamento era garantizar que los sistemas de IA utilizados en la UE sean **seguros**, **transparentes**, **trazables**, **no discriminatorios** y **respetuosos con el medio ambiente**.

Marco ético de la IA en Colombia

Colombia ha avanzado con un marco ético para el diseño y uso de la IA, proyectos de ley en desarrollo y documentos pioneros como los lineamientos para IA generativa en la educación.

El **CONPES 4144**, política nacional de inteligencia artificial, tiene como propósito fortalecer la capacidad del país en investigación, desarrollo y adopción de sistemas de IA.
Busca **promover** la innovación y la competitividad, pero también garantizar que estas tecnologías contribuyan a **cerrar la brecha digital** y no a ampliarla.



Soberanía Digital y Gobernanza de la IA?

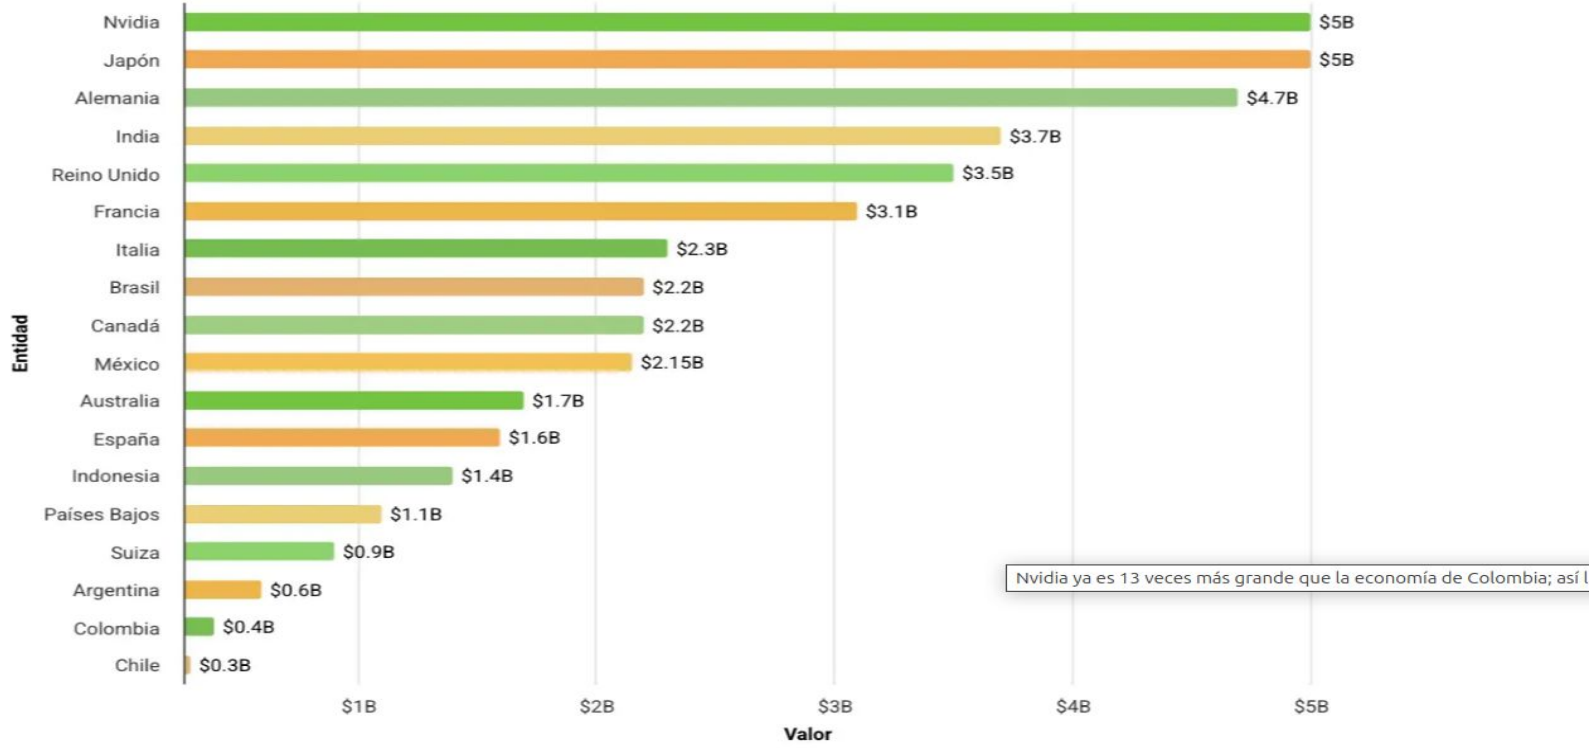
Soberanía digital ?







Soberanía Digital



https://www.elcolombiano.com/negocios/nvidia-vale-13-veces-economia-colombia-pib-alemani-japon-reino-unido-NF30600973

Inteligencia Artificial Agéntica?

Inteligencia Artificial Agéntica

"Los empleados estamos aterrados": la advertencia de un exinvestigador de Anthropic a la BBC sobre los riesgos de la IA (y por qué genera críticas)



Jacob Coxon, exempleado de Anthropic.

Jacob Coxon

Inteligencia Artificial Agéntica

npj | digital medicine

Article

Published in partnership with Seoul National University Bundang Hospital

https://doi.org/10.1038/s41746-026-02517-5

The role of agentic artificial intelligence in healthcare: a scoping review

https://www.researchsquare.com/article/rs-7234499/v1

Gracias

¿Preguntas?